

Prepoznavanje umjetno (AI) generiranih slika

Paula Močinić
Računarska znanost
FER
paula.mocinic@fer.hr

Mihael Pristav
Računarska znanost
FER
mihael.pristav@fer.hr

Fran Lubina
Računarska znanost
FER
fran.lubina@fer.hr

Ante Čavar
Računarska znanost
FER
ante.cavar@fer.hr

Sažetak—Ovaj dokument prikazuje naš proces i istraživanje kroz koje objašnjavamo na koji način smo razvili model koji prepoznaje AI generirane slike.

Index Terms—AI, deep-fake, perceptron

I. UVOD

Zadnjih par godina svjedočimo nevjerojatnom napretku generativnih modela poput GAN-ova i difuzijskih modela (npr. Stable Diffusion i Midjourney), koji su podigli kvalitetu umjetno generiranih slika na razinu koju je ljudskom oku gotovo nemoguće razlikovati od stvarnosti. Iako ova tehnologija nudi goleme kreativne mogućnosti, ona donosi i ozbiljne izazove u području digitalne forenzike i provjere informacija, jer se lažni vizualni sadržaji mogu lako koristiti za manipulaciju javnim mnijenjem ili krađu identiteta. U ovom projektu fokusirali smo se na razvoj sustava za automatsko prepoznavanje AI generiranih slika koristeći duboko učenje. Naš cilj je istražiti možemo li pomoću specifičnih arhitektura neuronskih mreža pouzdano "uhvatiti" suptilne tragove koje generativni procesi ostavljaju u pikselima.

A. Opis problema

Glavni zadatak koji rješavamo je binarna klasifikacija: moramo odrediti pripada li ulazna slika klasi "stvarnih" ili "AI generiranih" slika. Iako to na papiru zvuči jednostavno, u praksi je vrlo izazovno jer moderni generatori više ne ostavljaju očite pogreške u teksturama ili frekvencijskom spektru, što je ranije bio glavni način detekcije. Također, modeli moraju biti sposobni prepoznati slike iz različitih izvora, a ne samo iz onih na kojima su trenirani.

B. Motivacija

Glavni pokretač za ovaj rad je činjenica da povjerenje u digitalne medije rapidno opada. Željeli smo stvoriti alat koji bi mogao poslužiti u borbi protiv dezinformacija.

II. PREGLED LITERATURE

Pregledom dosadašnjih radova vidjeli smo da su konvolucijske neuronske mreže (CNN) i dalje "zlatni standard" za ovaj problem zbog svoje sposobnosti da izvuku lokalne značajke i teksturalne anomalije. Modeli poput ResNet-50 i EfficientNet-a često postižu točnost veću od 90% na standardnim skupovima podataka kao što je CIFAKE. Međutim, literatura također naglašava jedan veliki problem: generalizaciju. Modeli koji savršeno rade na slikama iz jednog generatora često potpuno zakazuju kada im se podmetne slika iz novijeg

ili drugačijeg modela. Novija istraživanja sugeriraju da bi rješenje moglo biti u promjeni klasifikacijske glave – na primjer, zamjenom standardnog Softmax sloja s SVM (Support Vector Machine) klasifikatorom, što u nekim slučajevima daje robusnije rezultate na rubnim primjerima.

III. RJEŠENJE

A. Opis i metodologija rada

Naše rješenje temelji se na usporedbi dvije varijante CNN modela. Oba modela koriste sličnu "okosnicu" za ekstrakciju značajki, ali se razlikuju u načinu donošenja konačne odluke: CNN s Softmax slojem: Klasičan pristup koji koristi kros-entropijsku funkciju gubitka i daje nam vjerojatnost pripadnosti klasi. Hibridni CNN-SVM model: Ovdje smo zadnji sloj mreže zamijenili SVM-om s linearnim kernelom. SVM pokušava maksimizirati marginu između stvarnih i lažnih slika u prostoru značajki koji je mreža naučila, što bi trebalo donijeti bolju separaciju klasa.

B. Opis rješenja

CNN koji smo koristili ima arhitekturu, odnosno slojeve kao na slici V.

Kao što je već ranije spomenuto (cjelina III-A) "okosnica", odnosno svi slojevi prije sloja za vektorizaciju je zajednički za sve modele. Kod CNN-SVM hibridne inačice se svi slojevi nakon toga jednostavno zamijene SVM-om. To je pak prikazano na slici VI

C. Optimizacija i treniranje

Da bismo izvukli maksimum iz oba modela, nismo nasumično birali parametre, već smo proveli Grid Search optimizaciju. Kod SVM-a smo sustavno varirali parametar regularizacije C i parametar γ (gamma) kako bismo pronašli idealan kompromis između točnosti na trening setu i sposobnosti generalizacije na novim podacima. Modeli su trenirani na CIFAKE datasetu koji sadrži 120,000 slika, što nam je osiguralo dovoljno veliku i balansiranu bazu za učenje.

Pri razvoju smo koristili:

- 1) Podjelu 8:72:20 za CNN inačicu
- 2) Podjelu 80:20 za SVM dio CNN-SVM Inačice.

Za obje inačice prvotni ispitni skup dijelimo na skup za skup za učenje i skup za testiranje u omjeru 80:20, za učenje CNN (što uključuje i "okosnicu" iz cjeline III-A) se daj skup dodatno dijeli u omjeru 90:10 na skup za učenje i skup za validaciju.





Slike su prije ulaza u mrežu normalizirane i skalirane na fiksnu rezoluciju (npr. 224×224 piksela) kako bi proces učenja bio stabilniji i brži. Uspjeh mjerimo kroz točnost (accuracy), ali i kroz konfuzijsku matricu kako bismo točno vidjeli koji tip slika model najčešće griješi.

D. Opis eksperimentalnih rezultata

Rezultati su dobiveni na podskupu CIFAKE skupa za testiranje (20k slika, 10k po kategoriji).

model	acc.	prec.	recall	f1-score
CNN	93.25%	0.90	0.97	0.94
CNN + SVM(linear)	94.31%	0.94	0.95	0.94
CNN + SVM(RBF)	94.59%	0.95	0.95	0.95

Odnosno, kada bi grafički prikazali točnost za sva tri modela:



IV. DISKUSIJA

A. O našim rezultatima

Na grafu točnosti vidimo da modeli svi imaju vrlo sličnu točnost. Što je i za očekivati obzirom da dijele većinu arhitekture. Samo je način donošenja odluke drugačiji nakon što su slike već vektorizirane. Također vidimo da CNN-SVM sa RBF kernelom ima najveću točnost. Autori misle da je razlogu tomu: 1) Krutost linearnog kernela 2) dodatni hiperparametar kod RBF kernela (preciznost). No detaljnija analiza nadilazi opseg i ciljeve ovog izvještaja.

U cjelini II je rečeno da je CNN "zlatni standard" za ovakve probleme. No vidimo da je moguće dobiti i bolje rezultate ako se izgradi mreža koja zadržava svu moć vektorizacije slike koju nude ulazni slojevi CNN mreža te se još k tome doda model strojnog učenja koji bolje klasificira primjere neko gusti slojevi.


B. Usporedba sa literaturom

Rezultati su vrlo slični, barem sa usporedivim arhitekturom, što je i za očekivati obzirom da je arhitektura mreže gotovo identična te da su skupovi podataka slične veličine. Naša mreža, napose SVM sa RBF kernelom ima nešto bolji rezultat. To je vjerojatno zbog poboljšane mogućnosti klasifikacije koju nudi kernel-SVM u odnosu na guste slojeve te zbog razloga navedenih u cjelini IV-A.


model	dataset	acc.	prec	recall	f1-score
CvT [1]	ArtiFact	98.54%	0.99	0.98	0.98
CNN [2]	Kaggle ai-get-img, CIFAKE, pygoogle	93.9%	0.97	0.91	0.94
ViT [3]	CIFAKE	98.25%	0.99	0.98	0.98

Međutim naši rezultati su znatno lošiji od novijih modela kao što su ViT transformatori ili modeli bazirani na njima (CvT). Transformatori bolje zadržavaju podatke nakon dugih sekvenci, odnosno između udaljenih piksela na istoj slici. Globalni uzorci se bolje raspoznavaju nego kod konvolucijskih mreža, bez gubitka kvalitete prepoznavanja lokalnih uzoraka.

V. ARHITEKTURA CNN



VI. ARHITEKTURA CNN-SVM



LITERATURA

- [1] Guyfloki (2023). AI Image Detector. GitHub. <https://github.com/guyfloki/ai-image-detector>
- [2] SanKolisetty (2023). AI Image Classifier. GitHub. <https://github.com/SanKolisetty/AI-Image-Classifier>
- [3] Dima806 (2024). CiFake: AI-Generated Image Detection with ViT. Kaggle. <https://www.kaggle.com/code/dima806/cifake-ai-generated-image-detection-vit>
- [4] Yu, Z., Li, X., Zhang, Z., Wang, Y. (2023). On the detection of AI-generated images. arXiv. <https://arxiv.org/abs/2302.11970>
- [5] GeeksforGeeks (2025). Convolutional Vision Transformer. <https://www.geeksforgeeks.org/computer-vision/convolutional-vision-transformer/>
- [6] Wikipedia contributors. Vision transformer. Wikipedia. https://en.wikipedia.org/wiki/Vision_transformer
- [7] Wikipedia contributors. Convolutional neural network. Wikipedia. https://en.wikipedia.org/wiki/Convolutional_neural_network
- [8] GeeksforGeeks (2025). Introduction to Convolutional Neural Network. <https://www.geeksforgeeks.org/machine-learning/introduction-convolution-neural-network/>
- [9] Shervine, S. (2025). CS230: Convolutional Neural Networks Cheatsheet. Stanford University. <https://stanford.edu/~shervine/teaching/cs-230/cheatsheet-convolutional-neural-networks>
- [10] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Houshy, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv. <https://arxiv.org/abs/2010.11929>